

(1)

نیالیه ۵۵ - ۹۸۱۰۸۱۲۴

تقرین سری ۱ - درس مادی ریاضی

(1)

الف - بنابر تعریف نرم F داریم:

$$\|A\|_F^2 = \sum_{i,j \in m,n} a_{ij}^2 \rightarrow \|UA\|_F^2 = \text{Tr}(UA)^T(UA)$$

$$= \text{Tr } A^T U^T U A = \|A\|_F^2$$

به طور مشابه برای $\|AV\|_F$ نیز داریم یعنی:

$$\|AV\|_F = \|A\|_F$$

$$\|A\|_F \xrightarrow{\text{SVD}} \|U^T \Sigma V\|_F = \|\Sigma\|_F = \sqrt{\sum_{i \in r} \sigma_i^2} \rightarrow \sigma_{\max}^2 \geq \sigma_i^2 \rightarrow \sigma_{\max} \leq \sqrt{\sum_{i \in r} \sigma_i^2} = \|A\|_F$$

$$\|A\|_F = \sqrt{\lambda_{\max}(A^*A)} \Rightarrow \sigma_i \geq 0 \rightarrow \sigma_{\max}^2 \leq \sum_{i \in r} \sigma_i^2 \Rightarrow \sigma_{\max} \leq \sqrt{\sigma_1^2 + \dots + \sigma_r^2}$$

$$\|A\|_F \leq \|A\|_F \leq \sqrt{\text{rank}(A)} \|A\|_F$$

$$E(x) = \int_{-\infty}^{\infty} x f(x) dx \xrightarrow{x \geq 0} E(x) = \int_0^{\infty} x f(x) dx$$

$$x = [0, a] \cup [a, \infty) \rightarrow E(x) = \int_0^a x f(x) dx + \int_a^{\infty} x f(x) dx$$

$$E(x) \geq \int_a^{\infty} x f(x) dx \geq \int_a^{\infty} a f(x) dx = a \int_a^{\infty} f(x) dx = a P(X \geq a)$$

$$\Rightarrow E(x) \geq a P(X \geq a)$$

$$\rightarrow P(X \geq a) \leq \frac{E(x)}{a}$$

$$\text{نتیجه‌گیری} \rightarrow P(Y \geq a) \leq \frac{E(Y)}{a} \text{ و } a > 0$$

ii.

$$\left. \begin{array}{l} Y = (X - \mu)^2 \\ a = \varepsilon^2 \end{array} \right\} \begin{array}{l} \text{متغیر تصادفی ثابته و عدد} \\ \text{variance of } X \end{array} \rightarrow P(Y \geq \varepsilon^2) \leq \frac{E(Y)}{\varepsilon^2}$$

$$E(Y) = E(X - \mu)^2 = \sigma^2$$

$$P(Y \geq \varepsilon^2) = P((X - E(X))^2 \geq \varepsilon^2) = P(|X - E(X)| \geq \varepsilon) \text{ و } E(X) = \mu$$

$$\Rightarrow P(|X - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}$$

— SOBHAN —

احتمال اینکه نقطه تصادفی ما در مدل درست واقع شود برابر مساحت دایرهی تقسیم به مساحت کل است . پس :

$$p = \frac{f\pi}{14} = \left\lfloor \frac{\pi}{4} \right\rfloor$$

برای تصدیق

$$E(x_i) = \frac{\pi}{4} \cdot 1 + \left(1 - \frac{\pi}{4}\right) \cdot 0 = \frac{\pi}{4}$$

$$V(x_i) = \frac{\pi}{4} \cdot \left(1 - \frac{\pi}{4}\right) \rightarrow \text{بله دایرهی تصادفی ما را به مساحت دایرهی تصادفی ما} \rightarrow$$

$$E(\hat{\pi}) = E\left(\frac{f}{n} \sum_{i=1}^n x_i\right) = \frac{f}{n} \sum_{i=1}^n E(x_i) = \pi$$

$$V(\hat{\pi}) = V\left(\frac{f}{n} \sum_{i=1}^n x_i\right) = \frac{f^2}{n^2} \sum_{i=1}^n V(x_i) = \frac{\pi(4-\pi)}{n}$$

$$P(|\hat{\pi}(n) - \pi| < \delta) > \epsilon$$

$$P(|\hat{\pi}(n) - \pi| \geq \delta) \leq 1 - \epsilon$$

$$\left. \begin{array}{l} \epsilon = 0.99 \\ \delta = 0.01 \end{array} \right\} \Rightarrow P(|\hat{\pi}(n) - \pi| \geq 0.01) \leq 1 - 0.99 = 0.01$$

از ضمیمه می دانیم $V(\hat{\pi})/\delta^2 \leq 0.01 \Rightarrow$ پس ضمیمه دایره :

$$\frac{V(\hat{\pi})}{\delta^2} = \frac{\pi(4-\pi)}{n(0.01)^2} \leq 0.01$$

$$\Rightarrow n \geq 39896.74 \Rightarrow \boxed{n \geq 39937}$$

یعنی حداقل باید ۳۹۹۳۷ نقطه تصادفی را

$$\vec{a^T} = a_1 x_1 + \dots + a_n x_n \quad \text{۲) اثبات -}$$

$$\frac{\partial \vec{a^T} x}{\partial x} = \left(\frac{\partial \vec{a^T} x}{\partial x_1}, \dots, \frac{\partial \vec{a^T} x}{\partial x_n} \right) = (a_1, \dots, a_n) = \boxed{\vec{a^T}}$$

$$x^T A x = \left(a_{11} x_1 + a_{12} x_2 + \dots + a_{1n} x_n \right), \dots, \left(a_{n1} x_1 + \dots + a_{nn} x_n \right) (x_1, \dots, x_n)^T$$

$$= \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j \rightarrow S$$

$$\frac{\partial x^T A x}{\partial x_i} = \frac{\partial S}{\partial x} = \left(\frac{\partial S}{\partial x_1}, \dots, \frac{\partial S}{\partial x_n} \right) = \sum_{j=1}^n (a_{ij} + a_{ji}) x_j$$

$$\Rightarrow \frac{\partial x^T A x}{\partial x} = \boxed{x^T (A + A^T)}$$

$$\frac{\partial (A^T A)}{\partial \beta} = \frac{\partial I}{\partial \beta} = \left(\frac{\partial A^T}{\partial \beta} A + A^T \frac{\partial A}{\partial \beta} \right) = 0$$

$$\Rightarrow \frac{\partial A^T}{\partial \beta} A = -A^T \frac{\partial A}{\partial \beta} \xrightarrow{\text{از اینجا}} \frac{\partial A^T}{\partial \beta} = \boxed{-A^T \frac{\partial A}{\partial \beta} A^T}$$

ت. K را به عنوان تابعی از n در نظر بگیرید:

$$|A| = \sum_{j=1}^n a_{kj} c_{kj} \rightarrow \frac{\partial |A|}{\partial a_{ij}} = c_{ij}$$

$$C = \frac{\partial |A|}{\partial A} \rightarrow A^{-1} = |A|^{-1} C \Rightarrow \nabla_A |A| = \boxed{|A| A^{-1}}$$

$$A^{-1} \xrightarrow{\text{طبق قضیه}} \nabla_A (|A| A^{-1}) = |A|^{-1} \nabla_A |A| \xrightarrow{\text{از اینجا}} \nabla_A \log |A|$$

$$\Rightarrow \nabla_A \log |A| = \boxed{A^{-1}}$$

(۴)

نیلمی - ۹۸۱.۸۱۴۴

تقریب سری ۱ - یادداشت

(۳) اف) می‌دانیم که معادله مشخصه ماتریس A $n \times n$ است به صورت زیر می‌باشد:

$$P(t) = \det(A - tI) = (-1)^n (t^n - (\text{tr}(A)) t^{n-1} + \dots + (-1)^n \det(A))$$

از طرفی داریم:

$$P(t) = (-1)^n (t - \lambda_1) \dots (t - \lambda_n) \rightarrow \boxed{\lambda_j \rightarrow \text{مقادیر ویژه}}$$

بنابراین با مقایسه ضرایب این دو برای ضرایب داریم:

$$\text{trace}(A) = \lambda_1 + \dots + \lambda_n$$

(ب)

$$\det(A - \lambda I) = P(\lambda) \leftarrow \text{بنابر تعریف}$$

$$P(\lambda) = (-1)^n (\lambda - \lambda_1) \dots (\lambda - \lambda_n)$$

$$= (-1)^n (\lambda - \lambda_1) \dots (-1)^n (\lambda - \lambda_n) = (\lambda_1 - \lambda) \dots (\lambda_n - \lambda)$$

یعنی ضرایب داریم $\lambda = 0$

بنابراین ضرایب داریم:

$$\det(A - 0I) = (\lambda_1 - 0) (\lambda_2 - 0) \dots (\lambda_n - 0)$$

$$\Rightarrow \det(A) = \lambda_1 \lambda_2 \dots \lambda_n$$

به طور اثبات می‌شود.

(5)

تقریباً یادگیری عمیق

(f) الف - میدانیم که وقتی $A^T A$ وارون پذیر است، سبب دارهای ستون خاصیت داشته باشند (ماتریس رتکستونی کامل داشته باشد). بنابراین $(A^T A)^{-1}$ وجود دارد و ما می‌توانیم آن را در دو طرف ضرب کنیم:

$$A^T = (A^T A)^{-1} A^T \Rightarrow A^T A A^T = A^T$$

از اینجا می‌توانیم رابطه‌های استفاده شده را ادامه بدهیم و می‌توانیم بگوییم که

A و A^+ را تقریب کرده و می‌توانیم و باز هم رابطه به هم می‌زنیم و به همان نتیجه می‌رسیم. داریم:

$$A = U \Sigma V^T$$

$$A^+ = V \Sigma^{-1} U^T$$

$$\begin{cases} V V^T = I \\ U^T U = I \end{cases} \text{ خاصیت ماتریس‌های U و V}$$

$$A^T = (U \Sigma V^T)^T = V \Sigma^T U^T$$

$$\rightarrow A^T A A^+ = A^T \approx (V \Sigma^T \underbrace{U^T U}_I \underbrace{V V^T}_I) V \Sigma^{-1} U^T = V \Sigma^T U^T$$

$$\Rightarrow V \Sigma^T \underbrace{\Sigma \Sigma^{-1}}_I U^T = V \Sigma^T U^T$$

که این عبارتی درست است و نتیجه می‌دهد.

ب - مشابه قبل، اگرگاه $A A^T$ وارون پذیر باشد، لازم است به دارهای سطرها مستقل باشد (ماتریس رتکستونی سطر کامل داشته باشد). پس $(A A^T)^{-1}$ وجود دارد و باز هم از ست راست آن A در دو طرف ضرب می‌کنیم:

$$A^T \cdot A^T (A A^T)^{-1} \rightarrow A^T A A^T = A^T$$

$$\Rightarrow V \Sigma^{-1} U^T (U \Sigma V^T V \Sigma^T U^T) = V \Sigma^T U^T$$

$$\rightarrow V \underbrace{\Sigma^{-1} \Sigma}_I \Sigma^T U^T = V \Sigma^T U^T$$

که باز هم عبارتی صحیح در آمده و حکم یکبار است.

(g) الف - طبق قضیه‌ی هلمهولد داریم: (هنگامی که A^{-1} وجود داشته باشد)

$$M = \begin{bmatrix} A & B \\ C & D \end{bmatrix} \quad M/A = D - C A^{-1} B$$

$$M = \begin{bmatrix} I & 0 \\ C A^{-1} & I \end{bmatrix} \begin{bmatrix} A & 0 \\ 0 & D - C A^{-1} B \end{bmatrix} \begin{bmatrix} I & A^{-1} B \\ 0 & I \end{bmatrix}$$

که M بصورت زیر تجزیه می‌شود:

$$M = \begin{bmatrix} I & 0 \\ C A^{-1} & I \end{bmatrix} \begin{bmatrix} A & 0 \\ 0 & D - C A^{-1} B \end{bmatrix} \begin{bmatrix} I & A^{-1} B \\ 0 & I \end{bmatrix}$$

و با جایگذاری $M/A = D - C A^{-1} B$ خواهیم داشت:

و می‌توانیم این قضیه مشخصات / طبق قانونی دترمینان ماتریسی طبقی - یاد داریم که

$$\det(M) = \det(AD - BC)$$

پس خواهیم داشت:

$$\det(M) = \det(I I - 0) \det(A(D - C A^{-1} B)) \det(I I - 0) = 1 \times \det(A(D - C A^{-1} B)) \times 1$$

و از توانی دترمینان:

$$\det(M) = \det(A) \det(D - C A^{-1} B)$$

(۷) ب - مانند قبلی، قبل از اینبار با دارون پذیر در نظر می‌گیریم D و ماتریس M را به سبب تفاوت قبضه‌پذیری نیز:

$$M = \underbrace{\begin{bmatrix} I & BD^{-1} \\ 0 & I \end{bmatrix}}_{\det \rightarrow 1} \underbrace{\begin{bmatrix} A - BD^{-1}C & 0 \\ 0 & D \end{bmatrix}}_{M/D} \underbrace{\begin{bmatrix} I & 0 \\ 0 & I \end{bmatrix}}_{\det \rightarrow 1} \rightarrow \det(M) = 1 \times \det((A - BD^{-1}C)D - 0 \times 0) \times 1$$

$$\Rightarrow \det(M) = \det(D) \det(A - BD^{-1}C)$$

پس این هم نیز اثبات است

پ - برای این قبلی، از دارون M استفاده می‌کنیم و همان‌طور که در مثال قبلی استفاده می‌کردیم:

$$M = \begin{bmatrix} A & B \\ C & D \end{bmatrix} \quad M^{-1} = \begin{bmatrix} E & F \\ G & H \end{bmatrix} \quad M^T M^{-1} = I \quad \left\{ \begin{bmatrix} A & B \\ C & D \end{bmatrix} \begin{bmatrix} E & F \\ G & H \end{bmatrix} = \begin{bmatrix} AE + BG & AF + BH \\ CE + DG & CF + DH \end{bmatrix} = \begin{bmatrix} I_A & 0 \\ 0 & I_D \end{bmatrix} \right.$$

پس مشاهده داریم:

$$\left\{ \begin{array}{l} AE + BG = I_A \quad (1) \\ AF + BH = 0 \quad (2) \\ CE + DG = 0 \quad (3) \\ CF + DH = I_D \quad (4) \end{array} \right. \quad \begin{array}{l} E = A^{-1} + A^{-1}BG \quad (1) \rightarrow \text{بافرض دارون پذیر بودن } A \\ (2) + (1) \rightarrow CA^{-1} + CA^{-1}BG + D^{-1}G \rightarrow (D + CA^{-1}B)G = -CA^{-1} \\ \rightarrow G = -(D + CA^{-1}B)^{-1}CA^{-1} \quad (5) \\ (4) + (5) \rightarrow \boxed{E = A^{-1} - A^{-1}B(D + CA^{-1}B)^{-1}CA^{-1}} \leftarrow \text{قضیه اول} \end{array}$$

یک جواب برای E بدست آوردیم - حال جواب دینا با فرض دارون پذیر بودن D بصورت زیر بدست می‌آید:

$$H = D^{-1} - D^{-1}CF \quad (6) \quad \begin{array}{l} (6) - (4) \rightarrow AF + BD^{-1} + BD^{-1}CF = 0 \rightarrow (A + BD^{-1}C)F = -BD^{-1} \\ F = -(M/D)^{-1}BD^{-1} \quad H = D^{-1} + D^{-1}C(M/D)^{-1}BD^{-1} \\ G = -D^{-1}CE \quad (7) \quad (7) + (1) \rightarrow AE + BD^{-1}CE = I_A \Rightarrow (A + BD^{-1}C)E = I_A \end{array}$$

$$\text{بافرض دارون پذیر بودن } D \rightarrow \boxed{E = (A + BD^{-1}C)^{-1}} \quad \leftarrow \text{قضیه دوم}$$

و از این دو بهایی که هم به حل اثبات می‌شود.

(2) ت - برای اثبات حکم با ابعاد خاص فرض را بر این می‌گذاریم که $A=I$ به قدر است. داریم:

$$\begin{bmatrix} I & 0 \\ v^T & 1 \end{bmatrix} \begin{bmatrix} I+uv^T & u \\ 0 & 1 \end{bmatrix} \begin{bmatrix} I & 0 \\ -v^T & 1 \end{bmatrix} = \begin{bmatrix} I & u \\ 0 & 1+v^T u \end{bmatrix}$$

با توجه به قوانین دترمینان به اندازه 1 داریم:

$$\det(I+uv^T) = \det(I+v^T u) \quad \text{و} \quad \det(I+v^T u) = 1+v^T u$$

مجموع کتب درسی و کتب مرجع با A داریم:

$$\det(A)$$

پس برای دترمینان هر ماتریس به شکل $(I+uv^T)$ داریم:

$$\det(I+uv^T) = 1+v^T u \quad (1)$$

$$-P = A^T u$$

$$A+uv^T = A(I+A^{-1}uv^T) \quad \det(I+uv^T) \xrightarrow{I+v^T u} \det(I+A^{-1}uv^T) \xrightarrow{(1)} \det(I+v^T A^{-1}u)$$

$$\Rightarrow \det(A+uv^T) = \det(A)(1+v^T A^{-1}u)$$

که این درستی حکم سوال را به ما نتیجه می‌دهد.

(3) اندام از بیگانه‌ها بیرون می‌آید و زیر استفاده می‌آید:

$$P_A(t) = \det \begin{pmatrix} tI_n - B & -x \\ -y^* & t-a \end{pmatrix}$$

$$= (t-a) \det(tI_n - B) - y^* (\text{adj}(tI_n - B)) x$$

پس می‌توان اینطور نوشت:

$$P_A(t) = (t-a) P_B(t) - y^* (\text{adj}(tI_n - B)) x$$

$$\begin{cases} \dim S_A = k+j \\ \dim S_B = n-j \end{cases}$$

ب- بنابر قضیه کورانت-فایر، زیرفضای S_A و S_B از F^n وجود دارند.

$$\begin{cases} \lambda_{k+j}(A) = \max_{\substack{x \in S_A \\ \|x\|=1}} \langle Ax, x \rangle \\ \lambda_{n-j}(B) = \max_{\substack{x \in S_B \\ \|x\|=1}} \langle Bx, x \rangle \end{cases}$$

$$\dim(S_A \cap S_B) \geq k$$

اما این پایه ای که است - فایر اعمال نمی شود و ثابت است:

$$\lambda_k(A+B) = \min_{\dim S=k} \max_{\substack{x \in S \\ \|x\|=1}} \langle (A+B)x, x \rangle \leq \min_{\substack{\dim S=k \\ S \subseteq S_A \cap S_B}} \max_{\substack{x \in S \\ \|x\|=1}} (\langle Ax, x \rangle + \langle Bx, x \rangle)$$

$$\leq \min_{\substack{\dim S=k \\ S \subseteq S_A \cap S_B}} \left(\max_{\substack{x \in S \\ \|x\|=1}} \langle Ax, x \rangle + \max_{\substack{x \in S \\ \|x\|=1}} \langle Bx, x \rangle \right) = \lambda_{k+j}(A) + \lambda_{n-j}(B) \quad \text{و } j=0, \dots, n-1$$

نه این درستی حکم را نتیجه می دهد.

ب- فرض می کنیم $x = (x_1, \dots, x_m, \dots, x_n) \in F^n$ و قضیه $\langle Bx, x \rangle = \langle Ax, x \rangle$ برقرار است.

و قضیه $\|x\| = \|y\|$ بنابر قضیه الف و ب داریم:

$$\lambda_k(A) = \min_{\substack{S \subseteq F^n \\ \dim S=k}} \max_{\substack{x \in S \\ \|x\|=1}} \langle Ax, x \rangle \leq \min_{\substack{S \subseteq \text{span}\{e_1, \dots, e_m\} \subseteq F^n \\ \dim S=k}} \max_{\substack{x \in S \\ \|x\|=1}} \langle Ax, x \rangle$$

$$= \min_{\substack{S \subseteq F^m \\ \dim S=k}} \max_{\substack{y \in S \\ \|y\|=1}} \langle By, y \rangle = \lambda_k(B)$$

حال وقتی $m=n-1$ قرار دهیم، به طور خاص به عبارتی دیگر:

$$\lambda_1(A) \leq \lambda_1(B) \leq \lambda_{n-1}(A) \leq \lambda_{n-1}(B) \leq \dots \leq \lambda_{n-1}(B) \leq \lambda_n(A)$$

که حکم نهایی سوال را اثبات می کند.

$$f(x) = \frac{1}{\theta^x} x e^{-\frac{x}{\theta}}, \quad 0 < \theta < \infty$$

$$L(\theta) = \frac{1}{\theta^n} \cdot e^{-\sum_{i=1}^n \frac{x_i}{\theta}} (x_1 \dots x_n), \quad \ell(\theta) = -n \log \theta - \frac{1}{\theta} n \bar{x} + \sum_{i=1}^n \log(x_i)$$

$$\ell'(\theta) = \frac{-n}{\theta} + \frac{n}{\theta^2} \bar{x} \rightarrow \ell'(\hat{\theta}) = 0 \rightarrow \frac{n}{\theta} = \frac{n}{\theta^2} \bar{x} \rightarrow \hat{\theta} = \bar{x}$$

به این به سادگی و به سادگی برای تابع $f(x)$ است.

$$x_i \sim N(\mu, \sigma^2) \quad \{x_i\}_{i=1}^N = S$$

$$P(S|M) \xrightarrow{\text{MLE}}$$

$$P(S|M) = \prod_{i=1}^N P(x_i|M) = \log \{P(S|M)\} \propto \sum_{i=1}^N -\frac{1}{\sigma^2} (M - x_i)^2$$

$$\rightarrow \frac{\partial \log \{P(S|M)\}}{\partial M} = 0 \Rightarrow \boxed{M_{ML} = \frac{1}{N} \sum_{i=1}^N x_i}$$

برای MLE داریم:

$$P(M|S) \propto P(S|M) \cdot P(M)$$

$$\left\{ \begin{aligned} P(M) \sim N(\mu, \sigma^2) &\Rightarrow \log \{P(M|S)\} \propto \sum_{i=1}^N \frac{1}{\sigma^2} (M - x_i)^2 + \frac{1}{\sigma^2} (M - \mu)^2 \end{aligned} \right.$$

$$\Rightarrow \frac{\partial \log \{P(M|S)\}}{\partial M} = 0 \Rightarrow \boxed{M_{MAP} = \frac{\sigma^2}{N\sigma^2 + \sigma^2} \sum_{i=1}^N x_i + \frac{\sigma^2}{N\sigma^2 + \sigma^2} \mu}$$

برای MAP داریم:

حال رفتارشان را در بینهایت بررسی می‌کنیم:

$$\xrightarrow{N \rightarrow \infty} M_{MAP} = \frac{1}{N} \sum_{i=1}^N x_i + 0 = \frac{\sum_{i=1}^N x_i}{N} = M_{ML}$$

سخت با هم برابر می‌شوند.

$$z = a + Ab$$

(9) الف)

$$A = - \sum_{ab} \sum_{bb}^{-1}$$

$$\text{Cov}(z, b) = \text{Cov}(a, b) + \text{Cov}(Ab, b) = \Sigma_{ab} + A \text{Var}(b) = \Sigma_{ab} - \Sigma_{ab} \Sigma_{bb}^{-1} \Sigma_{bb} = 0$$

$$E(z) = \mu_a + A \mu_b$$

پس z و b مستقل. پس واضح داریم:

$$\mu_{a|b} = E(x_a | b) = E(z - Ab | b)$$

$$= E(z) - E(Ab | b) = E(z) - Ab = \mu_a + A(\mu_b - x_b) = \boxed{\mu_a + \sum_{ab} \sum_{bb}^{-1} (x_b - \mu_b)}$$

نقطه اول

$$\text{Var}(x_a | x_b) = \text{Var}(z - Ax_b | x_b) = \text{Var}(z | x_b) + \text{Var}(-Ax_b | x_b) - A \text{Cov}(z, -x_b)$$

$$- \text{Cov}(z, -x_b) A' = \text{Var}(z | x_b) = \text{Var}(z)$$

پس داریم:

$$\text{Var}(x_a | x_b) = \text{Var}(z) = \text{Var}(x_a + Ax_b)$$

$$= \text{Var}(x_a) + A \text{Var}(x_b) A' + A \text{Cov}(x_a, x_b) + \text{Cov}(x_b, x_a) A'$$

$$= \Sigma_{aa} + \sum_{ab} \sum_{bb}^{-1} \sum_{bb} \sum_{bb}^{-1} \Sigma_{aa} - 2 \Sigma_{ab} \sum_{bb}^{-1} \Sigma_{ba} = \Sigma_{aa} + \Sigma_{ab} \sum_{bb}^{-1} \Sigma_{ba} - 2 \Sigma_{ab} \sum_{bb}^{-1} \Sigma_{ba}$$

$$= \boxed{\Sigma_{aa} - \Sigma_{ab} \sum_{bb}^{-1} \Sigma_{ba}}$$

پس و بایندهرت دو طرف متساوی است.

(ب) از امید ریاضی و تعریف آن استفاده می‌کنیم:

$$\begin{aligned} \text{Var}(E(x_a)) &= \int_{-\infty}^{+\infty} E(x_a | x_b = t) P(x_b = t) dx \\ &= \int_{-\infty}^{+\infty} \mu_a P(x_b = t) dx = \int_{-\infty}^{+\infty} \sum_{ab} \sum_{bb}^{-1} (t - \mu_b) A(x_b = t) dx \\ &= \mu_a - \sum_{ab} \sum_{bb}^{-1} \left(\int_{-\infty}^{+\infty} t P(x_b = t) dx - \mu_b \int_{-\infty}^{+\infty} P(x_b = t) dx \right) = \mu_a \end{aligned}$$

پس برای x_a برابر μ_a می‌شود (1)

$$\text{Var}(x_a) = \underbrace{E[\text{Var}(x_a | x_b)]}_{(1)} + \underbrace{\text{Var}(E[x_a | x_b])}_{(2)} \quad \text{تعریف (1)} \quad E[\text{Var}(x_a | x_b)] = E\left(\Sigma_{aa} - \sum_{ab} \sum_{bb}^{-1} \sum_{bb}\right) = \Sigma_{aa} - \sum_{ab} \sum_{bb}^{-1} \sum_{bb}$$

$$\text{Var}(E[x_a | x_b]) = \text{Var}\left(\mu_a + \sum_{ab} \sum_{bb}^{-1} (x_b - \mu_b)\right) = \text{Var}\left(\sum_{ab} \sum_{bb}^{-1} x_b\right) = \sum_{ab} \sum_{bb}^{-1} \text{Var}(x_b) \sum_{bb}^{-1} \Sigma_{bb} = \sum_{ab} \sum_{bb}^{-1} \sum_{bb} \sum_{bb}^{-1} \Sigma_{bb}$$

$$= \sum_{ab} \sum_{bb}^{-1} \Sigma_{bb} \rightarrow \text{Var}(x_a) = \textcircled{1} + \textcircled{2} = \Sigma_{aa} - \sum_{ab} \sum_{bb}^{-1} \sum_{bb} + \sum_{ab} \sum_{bb}^{-1} \sum_{bb} = \Sigma_{aa} \Rightarrow \boxed{x_a = N(\mu_a, \Sigma_{aa})}$$

(11)

تعریف سری ۱ - یارگیری عمیق

۱. ابتدا $\|Ax - b\|^2$ را به شکل زیر می بنویسیم

$$\|Ax - b\|^2 = (Ax - b)^T (Ax - b)$$

$$= (x^T A^T - b^T)(Ax - b) = x^T A^T A x - x^T A^T b - b^T A x - b^T b$$

می خواهیم ثابت -

$$\|Ax - b\|^2 = x^T A^T A x - 2x^T A^T b - b^T b$$

بامشقی سری از آن فواید ثابت -

$$\frac{\partial \|Ax - b\|^2}{\partial x} = 2A^T A x^* - 2A^T b = 0$$

بنابراین فرض می توانیم بنویسیم:

$$A^T A x^* = A^T b \Rightarrow x^* = (A^T A)^{-1} A^T b$$

که در اینجا x^* جواب سوال مای قبل، دیدیم یعنی اولین معادله بالا به این با A^+ است. پس:

$$x^* = A^+ b$$

ب -

$$x^{(t+1)} = x^{(t)} - \alpha A^T (Ax^{(t)} - b)$$

با فرض همرا بودن می توان گفت $x^{(t+1)} = x^*$ و $x^{(t)} = x^*$ و اینج آن را به اسلای داده زیر بدست می آوریم:

$$\alpha A^T A x^* - \alpha A^T b = 0$$

$$x^T A^T A x^* = x^T A^T b \Rightarrow x^* = (A^T A)^{-1} A^T b \rightarrow x^* = A^+ b$$

که نشان دهنده میل بودن x^* به $A^+ b$ در مقایسه با زیاد می باشد.